ĐẠI HỌC KINH TẾ QUỐC DÂN
VIỆN ĐÀO TẠO TIÊN TIẾN, CHẤT LƯỢNG CAO VÀ POHE (AEP)

BÀI TẬP LỚN - NHÓM 9
HỌC PHẦN KHOA HỌC DỮ LIỆU TRONG KINH TẾ VÀ KINH DOANH

BÁO CÁO CHỦ ĐỀ 10

Lớp tín chỉ: AEP.TOKT1138.LS(126)_01

Lớp: Kinh tế đầu tư CLC 66B

Thành viên: Nguyễn Chí Cường (11248219)
Lê Đức Thành (11247754)
Vũ An Phúc (11246954)
Phùng Quang Lượng (11243104)
Nguyễn Minh Hiếu (11243586)

Giảng viên: TS. Trần Đức Minh

HANOI - 2026

MỤC LỤC

TÓM TẮT....3
GIAI ĐOẠN 1: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU....4
1.1. Nguồn dữ liệu....4
1.1.1. Mục tiêu bài toán....4
1.2. Kiểm tra hiện trạng dữ liệu....6
1.2.1. Cấu trúc và kiểu dữ liệu....6
1.2.2. Giá trị khuyết thiếu....7
1.2.3. Tính nhất quán của dữ liệu....8
GIAI ĐOẠN 2: TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU....9
2.1. Dữ liệu trùng lặp....9
2.2. Sai định dạng và giá trị không nhất quán....9
2.3. Ngoại lệ (outliers)....10
2.4. Thiếu dữ liệu không ngẫu nhiên và rò rỉ mục tiêu....12
2.5. Giải trình lựa chọn kỹ thuật....13
GIAI ĐOẠN 3: PHÂN TÍCH VÀ TRỰC QUAN HÓA....16
3.1. Giả thuyết và phương pháp kiểm định....16
3.2. Biến số: năng lực tài chính và điểm tín dụng....16
3.3. Biến phân loại: sản phẩm, kênh và nhân khẩu học....18
3.4. Tương quan và tương tác giữa các biến....21
3.5. Kiểm chứng bằng mô hình dự báo....23
3.6. Tổng hợp kết quả kiểm định giả thuyết....24
GIAI ĐOẠN 4: ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ....26
4.1. Các phát hiện nổi bật....26
4.2. Đề xuất giải pháp....26

4.3. Giới hạn của tập dữ liệu..... 28

4.4. Hướng mở rộng trong tương lai.....28

PHỤ LỤC: TÁI LẬP KẾT QUẢ..... 29

TÓM TẮT

Báo cáo phân tích bộ dữ liệu Loan Default gồm 148.670 khoản vay thế chấp năm 2019 với 34 thuộc tính, nhằm trả lời câu hỏi: những yếu tố nào liên quan đến khả năng vỡ nợ của khoản vay, và ngân hàng có thể dùng dữ liệu để kiểm soát rủi ro như thế nào. Quy trình gồm bốn giai đoạn: thu thập và đánh giá dữ liệu; tiền xử lý và làm sạch; phân tích, kiểm định giả thuyết và trực quan hóa; đánh giá tác động và khuyến nghị. Toàn bộ quy trình được thực hiện bằng Python trong notebook đi kèm, và mọi con số trong báo cáo đều được tính trực tiếp từ dữ liệu.

Phát hiện quan trọng nhất nằm ở chất lượng dữ liệu. Ba cột lãi suất, chênh lệch lãi suất và phí trả trước bị thiếu ở gần như toàn bộ hồ sơ vỡ nợ, và một nhóm 15.648 hồ sơ ghi nhận không đầy đủ có tỷ lệ vỡ nợ 99,93%. Đây là hiện tượng rò rỉ mục tiêu (data leakage). Nếu không phát hiện, mô hình sẽ đạt AUC 0,997 một cách giả tạo. Sau khi tách nhóm này, phân tích trên 133.022 hồ sơ đầy đủ (tỷ lệ vỡ nợ 15,79%) cho thấy rủi ro chủ yếu do năng lực tài chính (DTI, LTV, thu nhập) và cấu trúc sản phẩm (trả gộp cuối kỳ, khấu hao âm), trong khi điểm tín dụng không có giá trị phân biệt. Mô hình Random Forest không dùng biến rò rỉ đạt AUC 0,813, và 20% hồ sơ rủi ro nhất chứa 58,9% số ca vỡ nợ.

GIAI ĐOẠN 1: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU

1.1. Nguồn dữ liệu

Bộ dữ liệu được chọn là Loan Default Dataset do tác giả Yasser H. công bố trên Kaggle (https://www.kaggle.com/datasets/yasserh/loan-default-dataset). Bộ dữ liệu gồm một file duy nhất Loan_Default.csv (khoảng 28,5 MB) với 148.670 quan sát và 34 thuộc tính. Mỗi dòng là một khoản vay thế chấp nhà ở năm 2019, gồm thông tin người vay (giới tính, tuổi, thu nhập, điểm tín dụng), thông tin khoản vay (số tiền, lãi suất, kỳ hạn, loại vay, mục đích vay), thông tin tài sản bảo đảm (giá trị tài sản, LTV) và biến kết quả Status.

1.1.1. Mục tiêu bài toán

Biến mục tiêu là Status (1 = khoản vay vỡ nợ, 0 = không vỡ nợ), nên đây là bài toán phân loại nhị phân. Mục tiêu phân tích gồm: (1) đánh giá chất lượng dữ liệu và độ tin cậy của từng trường; (2) xác định các yếu tố liên quan đến vỡ nợ thông qua kiểm định giả thuyết; (3) kiểm chứng bằng một mô hình dự báo và (4) đề xuất chính sách tín dụng dựa trên số liệu.

Kaggle không cung cấp từ điển dữ liệu chính thức. Ý nghĩa các cột trong Bảng 1 được suy luận từ tên cột, các giá trị quan sát được và quy ước phổ biến trong dữ liệu cho vay thế chấp.

Bảng 1. Danh sách thuộc tính của Loan_Default.csv

STT	Tên cột	Kiểu	Ý nghĩa (suy luận)	% Thiếu
1	ID	Số	Mã định danh hồ sơ (khóa chính)	0
2	year	Số	Năm của hồ sơ (chỉ có 2019)	0
3	loan_limit	Chữ	Loại hạn mức: cf (theo chuẩn) / ncf (vượt chuẩn)	2,25%
4	Gender	Chữ	Giới tính: Male, Female, Joint, Sex Not Available	0
5	approv_in_adv	Chữ	Được phê duyệt trước (pre / nopre)	0,61%
6	loan_type	Chữ	Loại khoản vay: type1, type2, type3	0
7	loan_purpose	Chữ	Mục đích vay: p1–p4 (đã mã hóa)	0,09%

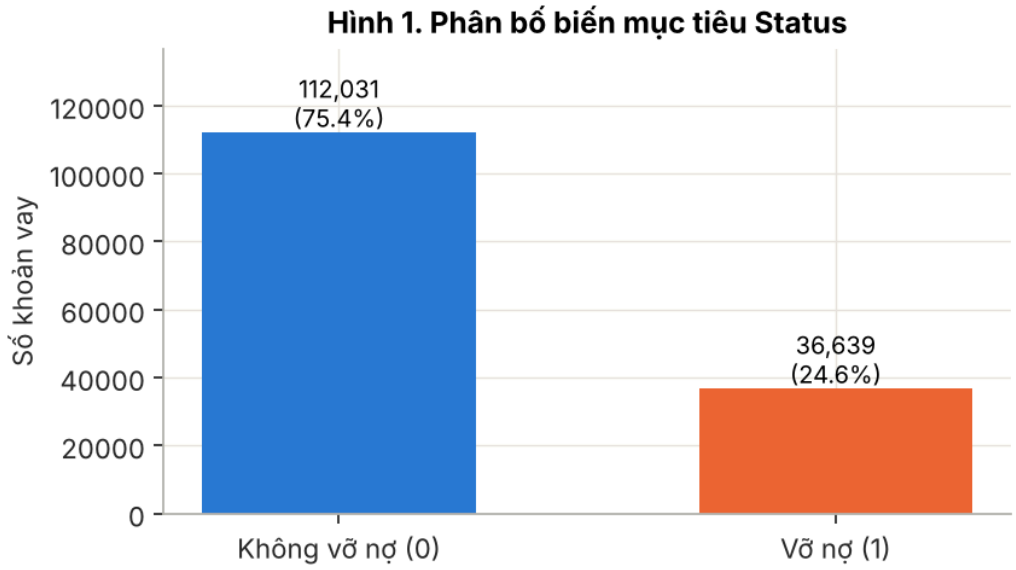
STT	Tên cột	Kiểu	Ý nghĩa (suy luận)	% Thiếu
8	Credit_Worthiness	Chữ	Mức tín nhiệm: l1 / l2	0
9	open_credit	Chữ	Có hạn mức tín dụng mở (opc / nopc)	0
10	business_or_commercial	Chữ	Vay kinh doanh/thương mại (b/c / nob/c)	0
11	loan_amount	Số	Số tiền vay	0
12	rate_of_interest	Số	Lãi suất (%)	24,51%
13	Interest_rate_spread	Số	Chênh lệch lãi suất so với lãi suất chuẩn	24,64%
14	Upfront_charges	Số	Phí trả trước khi giải ngân	26,66%
15	term	Số	Kỳ hạn vay (tháng)	0,03%
16	Neg_ammortization	Chữ	Khấu hao âm: dư nợ có thể tăng (neg_amm / not_neg)	0,08%
17	interest_only	Chữ	Giai đoạn chỉ trả lãi (int_only / not_int)	0
18	lump_sum_payment	Chữ	Trả gộp một lần cuối kỳ (lpsm / not_lpsm)	0
19	property_value	Số	Giá trị tài sản bảo đảm	10,16%
20	construction_type	Chữ	Loại công trình: sb (xây tại chỗ) / mh (nhà lắp ghép)	0
21	occupancy_type	Chữ	Mục đích sử dụng nhà: pr (ở chính), sr (nhà phụ), ir (đầu tư)	0
22	Secured_by	Chữ	Tài sản bảo đảm: home / land	0
23	total_units	Chữ	Số căn: 1U–4U	0
24	income	Số	Thu nhập (giả định theo tháng)	6,15%

STT	Tên cột	Kiểu	Ý nghĩa (suy luận)	% Thiếu
25	credit_type	Chữ	Tổ chức chấm điểm tín dụng: CIB, CRIF, EXP, EQUI	0
26	Credit_Score	Số	Điểm tín dụng (500–900)	0
27	co-applicant_credit_type	Chữ	Tổ chức chấm điểm của người đồng vay: CIB / EXP	0
28	age	Chữ	Nhóm tuổi: <25, 25-34, …, >74	0,13%
29	submission_of_application	Chữ	Kênh nộp hồ sơ: to_inst / not_inst	0,13%
30	LTV	Số	Tỷ lệ khoản vay / giá trị tài sản (%)	10,16%
31	Region	Chữ	Vùng: North, South, Central, North-East	0
32	Security_Type	Chữ	Hình thức bảo đảm: direct / Indriect	0
33	Status	Số	Biến mục tiêu: 1 = vỡ nợ, 0 = không vỡ nợ	0
34	dtir1	Số	Tỷ lệ nợ trên thu nhập – DTI (%)	16,22%

1.2. Kiểm tra hiện trạng dữ liệu

1.2.1. Cấu trúc và kiểu dữ liệu

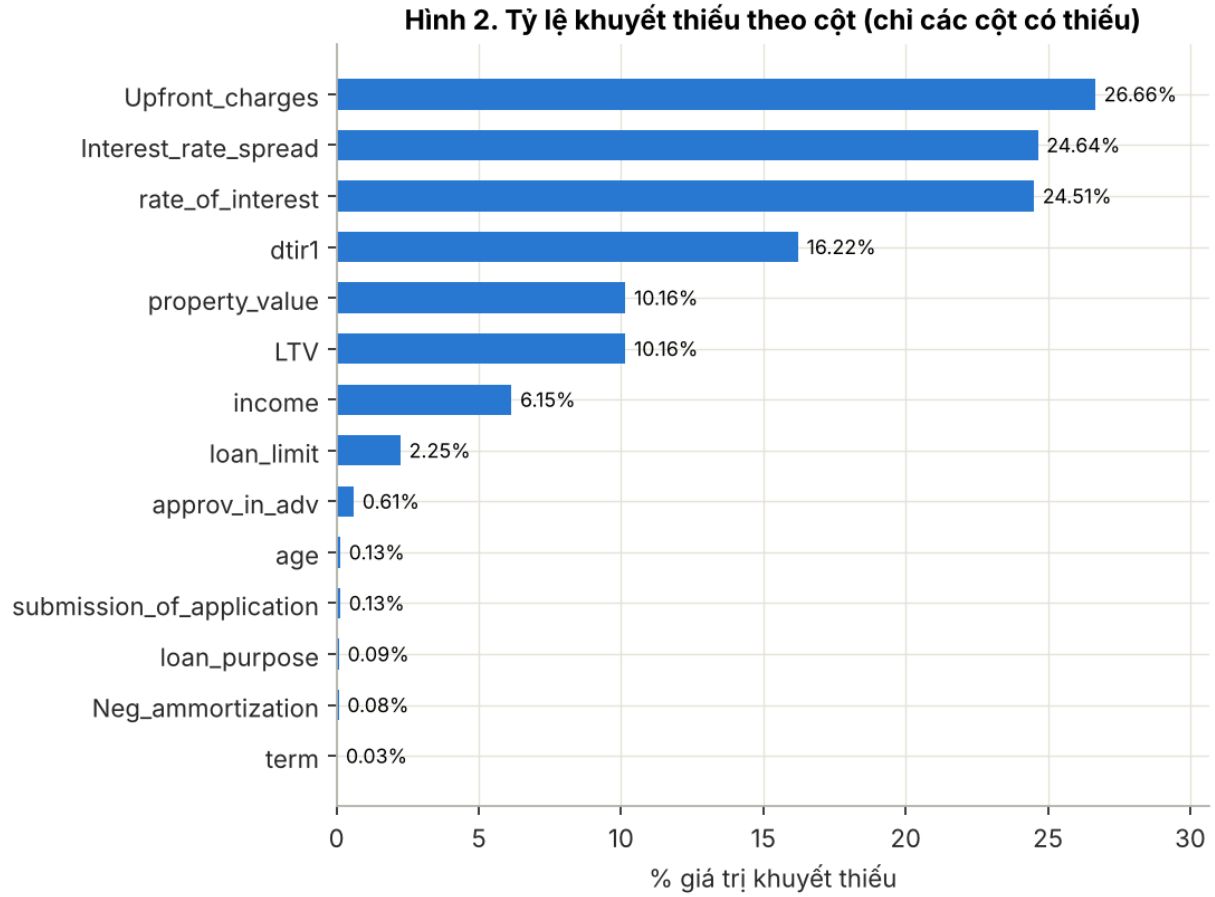
Dữ liệu có 13 cột số (8 cột thực, 5 cột nguyên) và 21 cột chữ. Kiểu dữ liệu của từng trường được nêu trong Bảng 1. Một số cột chữ thực chất có thứ bậc (age lưu dạng khoảng "25-34") hoặc là số được mã hóa thành chữ (total_units = "1U"–"4U"), nên cần chuyển đổi ở Giai đoạn 2. Dữ liệu chiếm khoảng 182,3 MB bộ nhớ khi nạp bằng pandas.



Hình 1. Phân bố biến mục tiêu Status

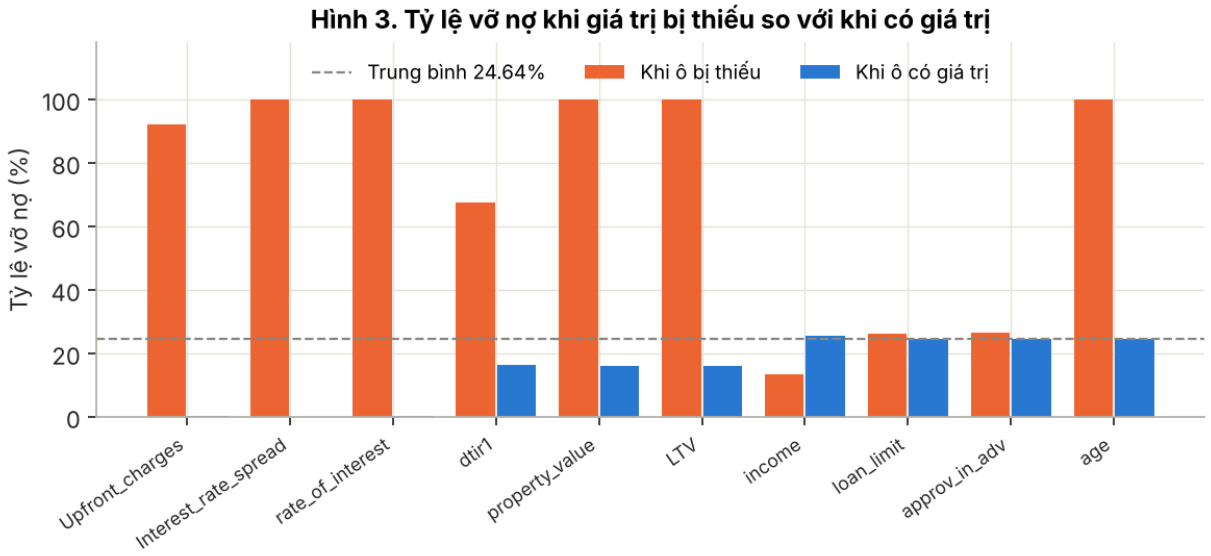
Trong 148.670 khoản vay có 112.031 khoản không vỡ nợ (75,36%) và 36.639 khoản vỡ nợ (24,64%), tỷ lệ khoảng 3:1. Dữ liệu mất cân bằng ở mức vừa phải: một mô hình luôn đoán "không vỡ nợ" đã đạt accuracy 75%, nên Accuracy không phải thước đo phù hợp. Bài học: khi đánh giá mô hình ở Giai đoạn 3 cần dùng AUC, Recall và Precision của lớp vỡ nợ, đồng thời chia train/test có phân tầng (stratify) và đặt class_weight="balanced".

1.2.2. Giá trị khuyết thiếu



Hình 2. Tỷ lệ khuyết thiếu theo cột

14/34 cột có giá trị thiếu và 33,96% số dòng thiếu ít nhất một ô, nên không thể xóa dòng thiếu (sẽ mất 1/3 dữ liệu). Có ba nhóm rõ rệt: (i) nhóm thiếu nặng 24–27% gồm Upfront_charges (26,66%), Interest_rate_spread (24,64%), rate_of_interest (24,51%); (ii) nhóm thiếu trung bình gồm dtir1 (16,22%), property_value và LTV (cùng 10,16%, vì LTV được tính từ property_value), income (6,15%); (iii) nhóm thiếu rất ít (<2,3%) như loan_limit, approv_in_adv, age. Điểm đáng chú ý: tỷ lệ thiếu của Interest_rate_spread (24,64%) trùng khớp với tỷ lệ vỡ nợ (24,64%). Đây là dấu hiệu đầu tiên cho thấy việc thiếu dữ liệu không ngẫu nhiên.



Hình 3. Tỷ lệ vỡ nợ khi giá trị bị thiếu so với khi có giá trị

Phân tích: Đây là phát hiện quan trọng nhất của khâu đánh giá dữ liệu. Khi rate_of_interest hoặc Interest_rate_spread bị thiếu, tỷ lệ vỡ nợ là 100%; khi có giá trị thì gần như bằng 0 (0,18% và 0%). Tương tự, property_value/LTV bị thiếu cho 99,99% vỡ nợ, age thiếu cho 100%, dtir1 thiếu cho 67,62% (so với 16,32% khi có). Ngược lại, income thiếu lại có tỷ lệ vỡ nợ thấp hơn (13,54% so với 25,37%). Kết luận: dữ liệu thiếu thuộc loại MNAR (thiếu phụ thuộc vào chính kết quả), nhiều khả năng do quy trình ghi nhận: hồ sơ vỡ nợ không được cập nhật lãi suất, phí, giá trị tài sản. Hệ quả là các cột này mang thông tin "rò rỉ" từ biến mục tiêu và không được điền thiếu một cách máy móc.

1.2.3. Tính nhất quán của dữ liệu

Bộ dữ liệu chỉ có một file nên không cần gộp bảng qua khóa chính/khóa ngoại. Thay vào đó, nhóm kiểm tra tính nhất quán bên trong file như sau:

Khóa chính ID: Duy nhất ở cả 148.670 dòng và liên tục từ 24.890 đến 173.559, không có dòng bị thiếu hay lặp mã.

Cột hằng: Year chỉ có giá trị 2019, không mang thông tin phân tích.

Công thức nội bộ: LTV = loan_amount / property_value × 100 khớp ở 100% số dòng có đủ hai giá trị, cho thấy LTV được tính từ hai cột kia chứ không phải nhập tay.

Cột trùng thông tin: business_or_commercial trùng hoàn toàn với loan_type = type2; Secured_by, construction_type và Security_Type cùng tách ra đúng 33 dòng giống nhau.

Thiếu dữ liệu có hệ thống: Các cột lãi suất/phí và property_value/LTV bị thiếu gần như chỉ ở hồ sơ vỡ nợ (Hình 3), đây là vấn đề nhất quán nghiêm trọng nhất và được xử lý ở Giai đoạn 2.

GIAI ĐOẠN 2: TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU

2.1. Dữ liệu trùng lặp

Dùng phương thức duplicated() của pandas để kiểm tra trên hai mức: trùng toàn bộ dòng (0 dòng) và trùng mọi cột trừ ID (0 dòng). Kết quả bằng 0 ở cả hai mức nên dữ liệu không có bản ghi trùng lặp và không cần xử lý. Việc kiểm tra mức thứ hai là cần thiết vì một khoản vay có thể bị nhập hai lần với hai mã ID khác nhau.

2.2. Sai định dạng và giá trị không nhất quán

Bảng 2 liệt kê các vấn đề định dạng tìm được khi rà soát giá trị duy nhất của từng cột chữ và kiểm tra miền giá trị của cột số.

Bảng 2. Các vấn đề định dạng và nhất quán

Vấn đề	Minh chứng	Cách xử lý
age lưu dạng chuỗi khoảng ("25-34", ">74")	7 mức, 200 dòng thiếu	Mã hóa thứ tự 0–6 (age_ord)
total_units lưu dạng chuỗi "1U"–"4U"	1U: 146.480; 2U: 1.477; 3U: 393; 4U: 320	Giữ là biến phân loại, One-Hot
Lỗi chính tả Security_Type = "Indriect"	33 dòng	Sửa thành "Indirect"
Region viết hoa không nhất quán	"North", "North-East" nhưng "south", "central"	Chuẩn hóa về dạng Title Case
Cột hằng year	Chỉ một giá trị 2019	Loại bỏ
Cột trùng thông tin	business_or_commercial = b/c đúng khi loan_type = type2 (20.762 dòng); Secured_by = land ≡ construction_type = mh ≡ Security_Type = Indriect (cùng 33 dòng)	Chỉ giữ loan_type trong mô hình

Vấn đề	Minh chứng	Cách xử lý
Giá trị phi lý	LTV tối đa 7.831% (1.799 dòng LTV > 100%); income = 0 ở 1.260 dòng; rate_of_interest = 0 ở 1 dòng	Winsorize LTV; income = 0 đưa vào nhóm hồ sơ không đầy đủ
term có 26 giá trị khác nhau	360 tháng chiếm 121.685 dòng; có kỳ hạn lẻ 165, 280, 322 tháng (mỗi giá trị 1 dòng)	Giữ nguyên, dùng như biến số
Upfront_charges = 0	20.770 dòng	Hợp lệ (không thu phí), giữ nguyên
Kiểm tra công thức LTV = loan_amount / property_value × 100	Khớp 100% số dòng có đủ dữ liệu	Không cần sửa; xác nhận tính nhất quán nội bộ

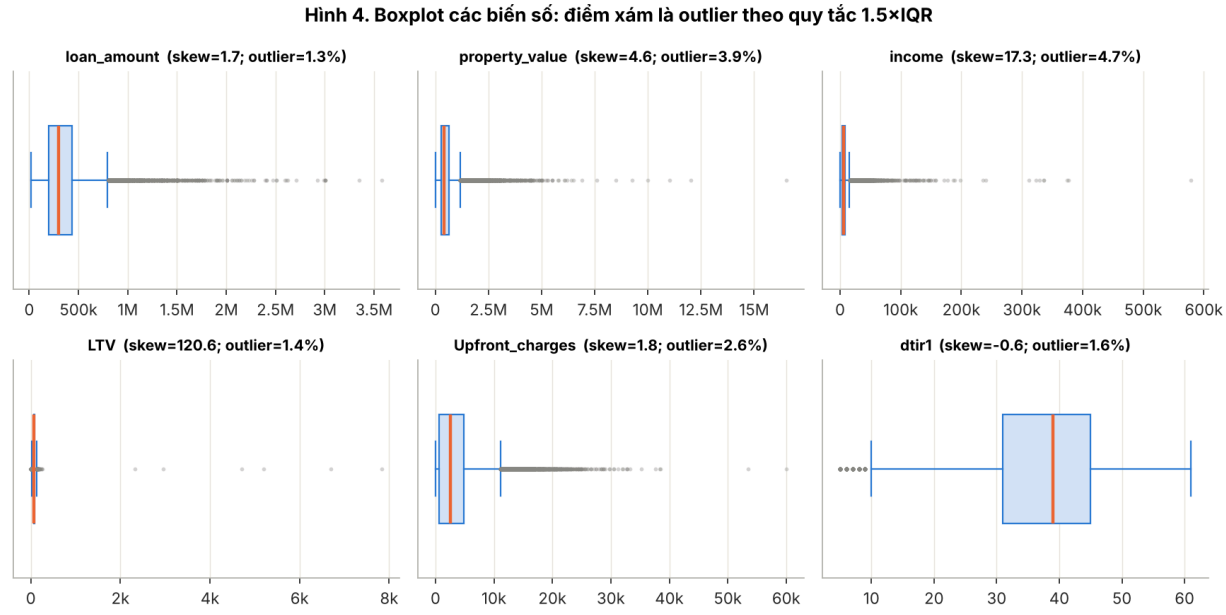
2.3. Ngoại lệ (outliers)

Ngoại lệ được phát hiện bằng quy tắc 1,5×IQR (giá trị nằm ngoài [Q1 - 1,5×IQR; Q3 + 1,5×IQR]) kết hợp so sánh giá trị lớn nhất với phân vị 99 (p99). Một biến có max lớn hơn p99 nhiều lần cho thấy đuôi phân phối rất dài hoặc có lỗi nhập liệu.

Bảng 3. Thống kê mô tả và ngoại lệ của biến số (dữ liệu gốc)

Biến	Mean	Median	Skew	Ngưỡng trên IQR	% outlier	p99	Max
loan_amount	331.118	296.500	1,67	796.500	1,27%	856.500	3.576.500
rate_of_interest	4,05	3,99	0,39	5,50	0,76%	5,50	8,00
Interest_rate_spread	0,44	0,39	0,28	1,82	0,40%	1,62	3,36
Upfront_charges	3.225	2.596	1,75	11.159	2,64%	14.297	60.000

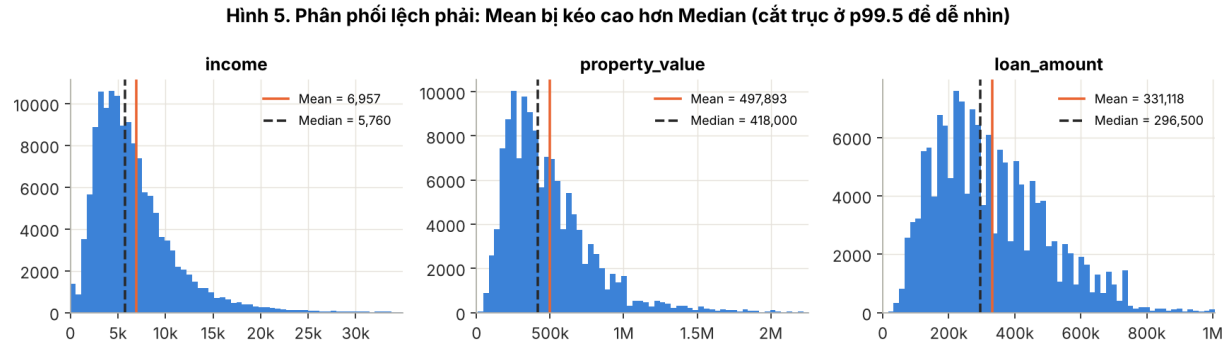
Biến	Mean	Median	Skew	Ngưỡng trên IQR	% outlier	p99	Max
term	335	360	-2,18	360	18,13 %	360	360
property_value	497.893	418.000	4,59	1.168.000	3,94%	1.808.000	16.508.000
income	6.957	5.760	17,31	15.720	4,69%	26.640	578.580
Credit_Score	700	699	0,01	1.102	0,00%	897	900
LTV	72,75	75,14	120,62	125	1,41%	103	7.831
dtir1	37,73	39,00	-0,55	66,00	1,62%	60,00	61,00



Hình 4. Boxplot các biến số và ngoại lệ theo quy tắc 1,5×IQR

Các biến tiền tệ đều lệch phải mạnh: property_value (skew 4,6; 3,9% outlier, max 16,5 triệu so với p99 là 1,81 triệu), income (skew 17,3; 4,7% outlier, max 578.580 so với p99 26.640), loan_amount (skew 1,7; 1,3% outlier). LTV có skew 120,6 do vài giá trị phi lý (max 7.831%, trong khi p99 là 102,8%), đây là lỗi dữ liệu chứ không phải khách hàng thật. Ngược lại dtir1 gần đối xứng (skew -0,6). Riêng term có 18,13% "outlier" theo IQR chỉ vì Q1 = Q3 = 360 tháng (IQR = 0), đây là kỳ hạn hợp lệ (180, 240 tháng) nên không coi là

ngoại lệ. Bài học: quy tắc IQR cần đi kèm hiểu biết nghiệp vụ; cách xử lý được chọn là winsorize (giới hạn tại p1–p99) thay vì xóa dòng.

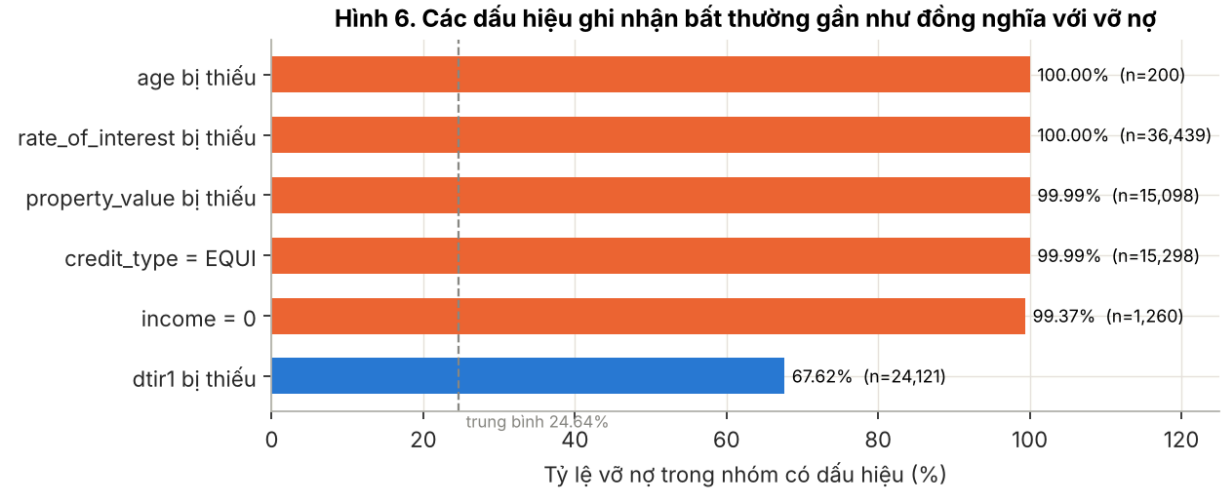


Hình 5. Phân phối lệch phải: Mean bị kéo cao hơn Median

Với income, Mean = 6.957 nhưng Median = 5.760 (Mean cao hơn 21%); property_value: Mean = 497.893 so với Median = 418.000 (cao hơn 19%); loan_amount: 331.118 so với 296.500 (cao hơn 12%). Đuôi phải dài kéo Mean lên, trong khi Median phản ánh đúng "khách hàng điển hình". Đây là minh chứng định lượng cho lựa chọn điền thiếu bằng Median thay vì Mean ở Giai đoạn 2.

2.4. Thiếu dữ liệu không ngẫu nhiên và rò rỉ mục tiêu

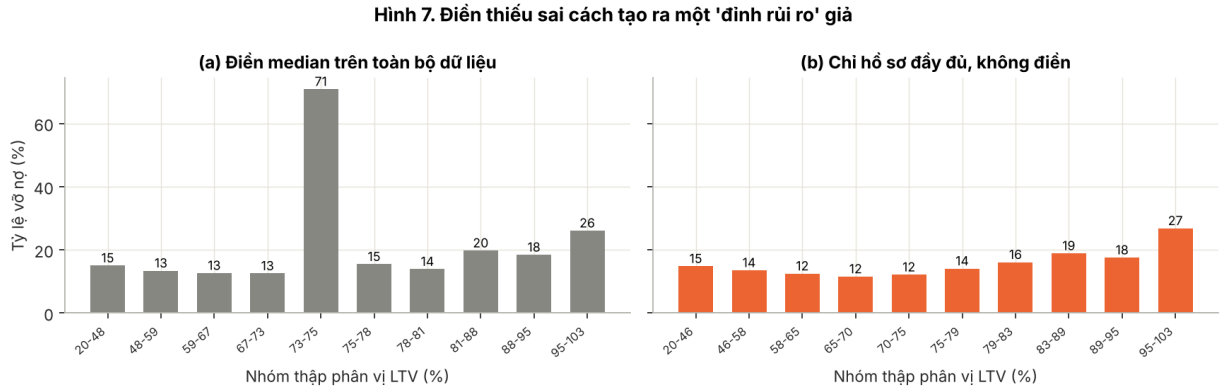
Từ Hình 3, nhóm gom các dấu hiệu ghi nhận bất thường thành một cờ incomplete_record = (property_value thiếu) HOẶC (credit_type = EQUI) HOẶC (age thiếu) HOẶC (income = 0), sau đó đo mức độ trùng khớp của cờ này với Status.



Hình 6. Các dấu hiệu ghi nhận bất thường gần như đồng nghĩa với vỡ nợ

Năm dấu hiệu cho tỷ lệ vỡ nợ từ 99,37% đến 100%: rate_of_interest thiếu (36.439 dòng, bao trùm 99,45% số ca vỡ nợ), credit_type = EQUI (15.298 dòng), property_value

thiếu (15.098 dòng), income = 0 (1.260 dòng) và age thiếu (200 dòng). Chỉ riêng cờ "rate_of_interest bị thiếu" đã cho AUC = 0,997 khi dự báo Status. Không có quy luật kinh tế nào giải thích được việc mọi hồ sơ do EQUI chấm điểm đều vỡ nợ, nên đây là dấu vết của quy trình thu thập chứ không phải hành vi khách hàng. Nhóm gộp "hồ sơ không đầy đủ" (property_value thiếu, EQUI, age thiếu hoặc income = 0) có 15.648 dòng, tỷ lệ vỡ nợ 99,93% và chiếm 42,68% tổng số ca vỡ nợ. Nhóm hồ sơ đầy đủ còn 133.022 dòng với tỷ lệ vỡ nợ 15,79%, và đây là nhóm được dùng để phân tích quan hệ ở Giai đoạn 3.



Hình 7. Điền thiếu sai cách tạo ra một "đỉnh rủi ro" giả

Nếu điền Median (75,1%) cho LTV trên toàn bộ dữ liệu rồi chia nhóm, nhóm LTV 73–75% có tỷ lệ vỡ nợ 70,85% (22.514 hồ sơ), trong khi các nhóm lân cận chỉ 12,5–15,5%. Đỉnh này hoàn toàn giả tạo: 15 nghìn hồ sơ vỡ nợ bị thiếu property_value đã bị dồn vào đúng giá trị Median. Khi chỉ dùng hồ sơ đầy đủ (hình b), quan hệ thật hiện ra: tỷ lệ vỡ nợ giảm nhẹ từ 14,82% xuống 11,57% ở LTV 65–70%, rồi tăng đều lên 26,81% ở nhóm LTV 95–103%. Đây là minh chứng rằng lựa chọn kỹ thuật điền thiếu có thể đảo ngược kết luận phân tích.

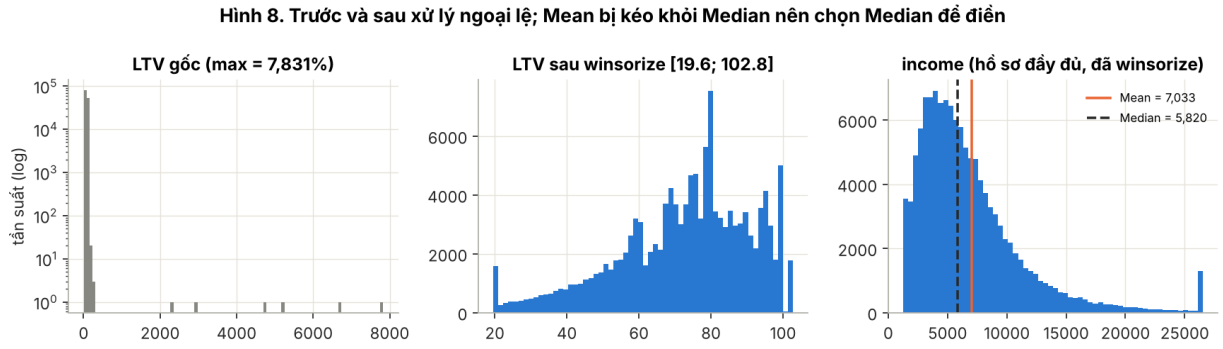
2.5. Giải trình lựa chọn kỹ thuật

Bảng 4 tóm tắt từng quyết định xử lý, lý do dựa trên số liệu, và phương án thay thế đã cân nhắc nhưng không chọn. Mọi bước điền thiếu và chuẩn hóa ở phần mô hình đều được đặt trong Pipeline của scikit-learn, chỉ học tham số (median, IQR, mode) trên tập train rồi áp dụng cho tập test, để tránh rò rỉ thông tin từ tập test.

Bảng 4. Giải trình lựa chọn kỹ thuật tiền xử lý

Vấn đề	Kỹ thuật chọn	Lý do (minh chứng)	Phương án không chọn
Thiếu ở rate_of_interest, Interest_rate_spread, Upfront_charges (24–27%)	Loại khỏi mô hình, không điền	Thiếu ở 99,45–100% hồ sơ vỡ nợ và gần 0% hồ sơ tốt; một cờ thiếu cho AUC 0,997. Đây là rò rỉ mục tiêu	Điền Mean/Median: mô hình đạt điểm cao giả tạo nhưng vô dụng với hồ sơ mới
Hồ sơ không đầy đủ (15.648 dòng)	Tách riêng; phân tích quan hệ trên 133.022 hồ sơ đầy đủ	Tỷ lệ vỡ nợ 99,93%; nếu điền sẽ tạo đỉnh rủi ro giả 70,85% (Hình 7)	Điền trên toàn bộ dữ liệu
Thiếu income (6,72%), dtir1 (6,63%) trong nhóm đầy đủ	Median + cột cờ thiếu (add_indicator), fit chỉ trên tập train	income lệch phải (skew 18,5; Mean 7.033 so với Median 5.820). Hồ sơ thiếu income/dtir1 có tỷ lệ vỡ nợ 11,5% so với 16,1% nên cờ thiếu mang thông tin	Mean (bị đuôi phải kéo lệch); xóa dòng (mất khoảng 13% dữ liệu)
Thiếu biến phân loại (loan_limit 2,23%, approv_in_adv 0,61%, …)	Mode (giá trị phổ biến nhất)	Tỷ lệ thiếu nhỏ; tỷ lệ vỡ nợ khi thiếu gần bằng khi có (loan_limit 26,35% so với 24,61%) nên gần như thiếu ngẫu nhiên	Tạo nhóm "Unknown" (thêm cột không cần thiết)
Ngoại lệ ở biến tiền tệ và LTV	Winsorize tại p1–p99	Giữ 100% số dòng; LTV 7.831% là lỗi, còn thu nhập cao là thật nên chỉ cần giới hạn ảnh hưởng	Xóa theo IQR: mất 4,7% income và 18% term (vì IQR của term = 0)
Biến danh nghĩa 2–4 mức	One-Hot (bỏ một cột với biến nhị phân)	Không có thứ bậc; số mức ít nên chỉ tạo 34 cột	Label Encoding: tạo thứ tự giả (type1 < type2 < type3)

Vấn đề	Kỹ thuật chọn	Lý do (minh chứng)	Phương án không chọn
age	Ordinal Encoding 0–6	Các nhóm tuổi có thứ bậc tự nhiên	One-Hot (mất thông tin thứ tự)
Thang đo khác nhau (income hàng nghìn, loan_amount hàng trăm nghìn)	RobustScaler (trừ Median, chia IQR)	Biến vẫn lệch phải sau winsorize; Logistic Regression cần các biến cùng thang đo	StandardScaler (Mean/Std bị outlier chi phối); MinMax (bị nén bởi giá trị max)
Mất cân bằng lớp (15,79% vỡ nợ trong nhóm đầy đủ)	class_weight = balanced, chia train/test phân tầng, đánh giá bằng AUC/Recall	Accuracy dễ gây hiểu lầm khi lớp thiểu số nhỏ	SMOTE (sinh dữ liệu nhân tạo, dễ rò rỉ nếu làm trước khi chia)



Hình 8. Trước và sau xử lý ngoại lệ

LTV gốc trải tới 7.831% (trục log cho thấy vài điểm cô lập ở 2.000–8.000%); sau khi winsorize tại p1–p99, LTV nằm trong [19,6%; 102,8%], đúng miền nghiệp vụ của khoản vay thế chấp, và phân phối có các đỉnh ở 80% và 100% (các ngưỡng LTV phổ biến khi cho vay). Với income trong nhóm hồ sơ đầy đủ, Mean = 7.033 vẫn lệch khỏi Median = 5.820 (skew 18,5), nên Median được dùng để điền 6,72% income còn thiếu. Winsorize giữ nguyên 100% số dòng (không làm mất thông tin về khách hàng thu nhập cao), chỉ giới hạn ảnh hưởng của giá trị cực đoan.

GIAI ĐOẠN 3: PHÂN TÍCH VÀ TRỰC QUAN HÓA

3.1. Giả thuyết và phương pháp kiểm định

Phân tích được thực hiện trên 133.022 hồ sơ đầy đủ (tỷ lệ vỡ nợ 15,79%), để kết luận không bị chi phối bởi lỗi ghi nhận. Dựa trên kinh nghiệm thẩm định tín dụng, nhóm đặt ra sáu giả thuyết ban đầu:

H1: Điểm tín dụng (Credit_Score) càng thấp, tỷ lệ vỡ nợ càng cao.

H2: Tỷ lệ khoản vay trên giá trị tài sản (LTV) càng cao, tỷ lệ vỡ nợ càng cao.

H3: Tỷ lệ nợ trên thu nhập (dtir1) càng cao, tỷ lệ vỡ nợ càng cao.

H4: Thu nhập càng cao, tỷ lệ vỡ nợ càng thấp.

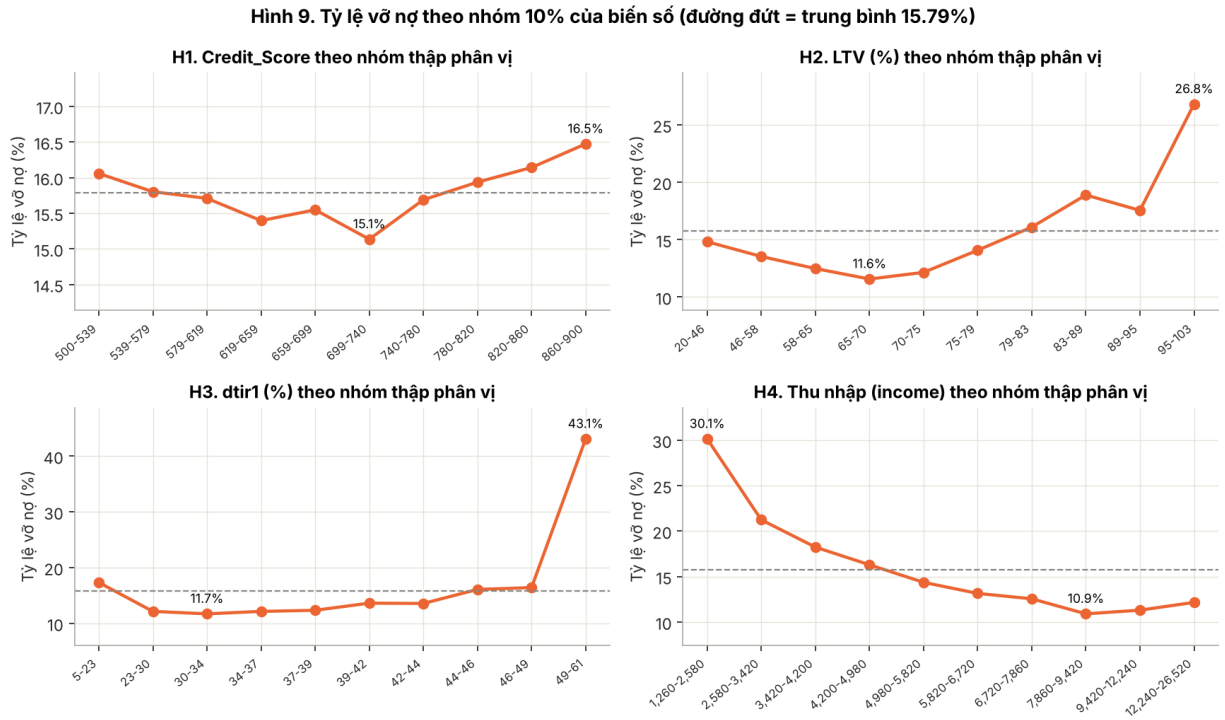
H5: Nhóm tuổi có liên hệ với khả năng vỡ nợ (người trẻ rủi ro hơn).

H6: Đặc điểm sản phẩm vay, vùng và giới tính có liên hệ với khả năng vỡ nợ.

Phương pháp: với biến số, dùng kiểm định Mann–Whitney U (phi tham số, vì các biến không phân phối chuẩn và có ngoại lệ) kèm hệ số rank-biserial (r_rb) để đo độ lớn hiệu ứng; với biến phân loại, dùng kiểm định Chi-square kèm Cramér's V. Mức ý nghĩa 5%. Vì cỡ mẫu rất lớn, hầu hết kiểm định đều có p rất nhỏ, nên kết luận dựa chủ yếu vào độ lớn hiệu ứng và mức chênh lệch tỷ lệ vỡ nợ giữa các nhóm.

3.2. Biến số: năng lực tài chính và điểm tín dụng

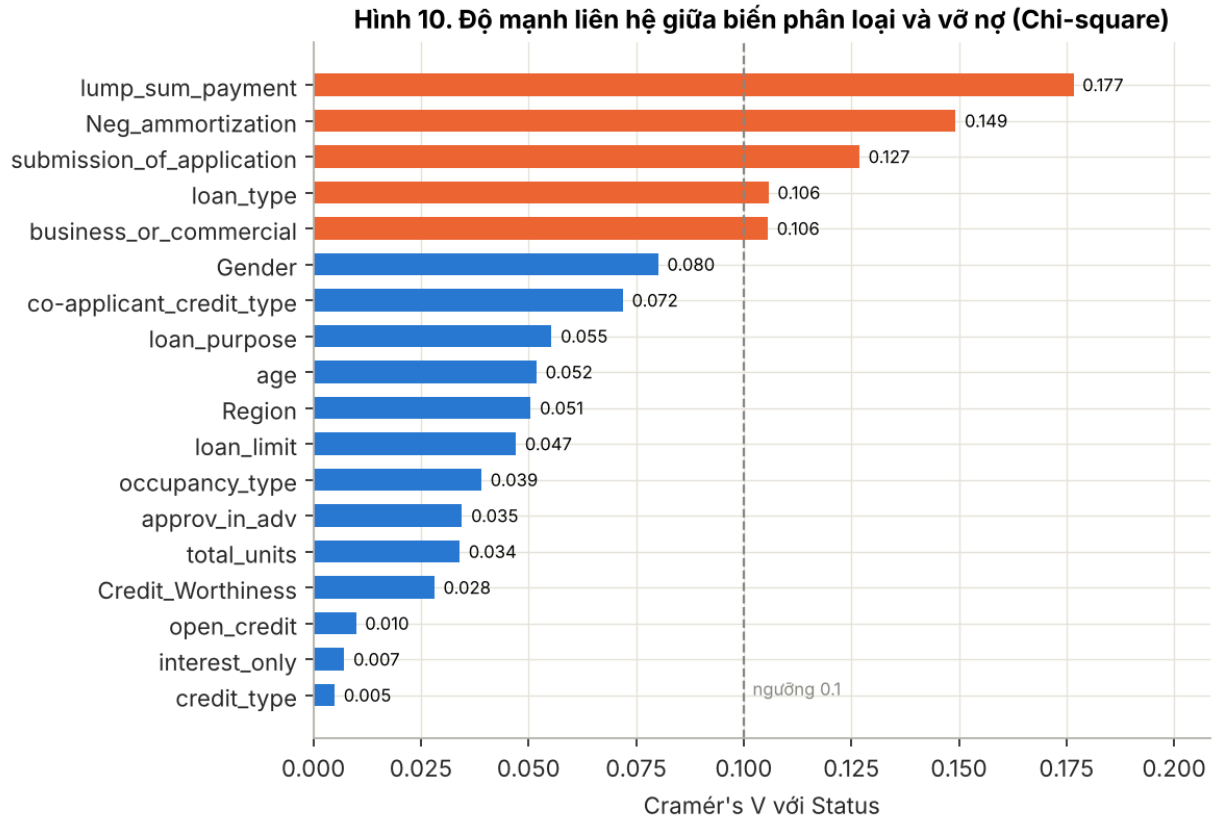
Biểu đồ đường theo thập phân vị được chọn vì nó cho thấy hình dạng quan hệ (tuyến tính, chữ U hay có ngưỡng), điều mà một hệ số tương quan không thể hiện được.



Hình 9. Tỷ lệ vỡ nợ theo nhóm thập phân vị của các biến số chính (hồ sơ đầy đủ)

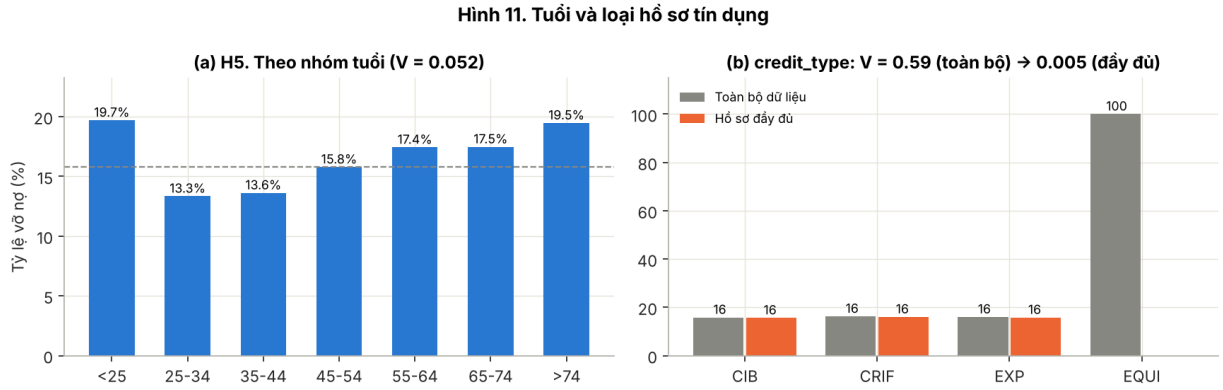
H1 (Credit_Score): tỷ lệ vỡ nợ chỉ dao động 15,1–16,5% giữa 10 nhóm điểm, đường gần như phẳng; kiểm định Mann–Whitney p = 0,19, Spearman ρ = 0,004, nên bác bỏ H1. H2 (LTV): đường hình chữ J, thấp nhất 11,57% ở LTV 65–70% và cao nhất 26,81% ở LTV 95–103% (gấp 2,3 lần); median LTV của nhóm vỡ nợ là 79,4% so với 74,5% ($p < 10^{-200}$). H3 (dtir1): đường phẳng quanh 12–16% cho tới dtir1 ≈ 49%, rồi nhảy vọt lên 43,09% ở nhóm 49–61% (gấp 3,7 lần mức thấp nhất). Quan hệ mang tính ngưỡng chứ không tuyến tính. H4 (income): giảm đơn điệu từ 30,14% ở nhóm thu nhập thấp nhất (1.260–2.580) xuống khoảng 11% từ mức 7.860 trở lên; median thu nhập nhóm vỡ nợ là 4.680 so với 6.000. Bài học: ba biến năng lực tài chính (LTV, dtir1, income) có tác động rõ, còn điểm tín dụng trong bộ dữ liệu này gần như không có giá trị phân biệt.

3.3. Biến phân loại: sản phẩm, kênh và nhân khẩu học



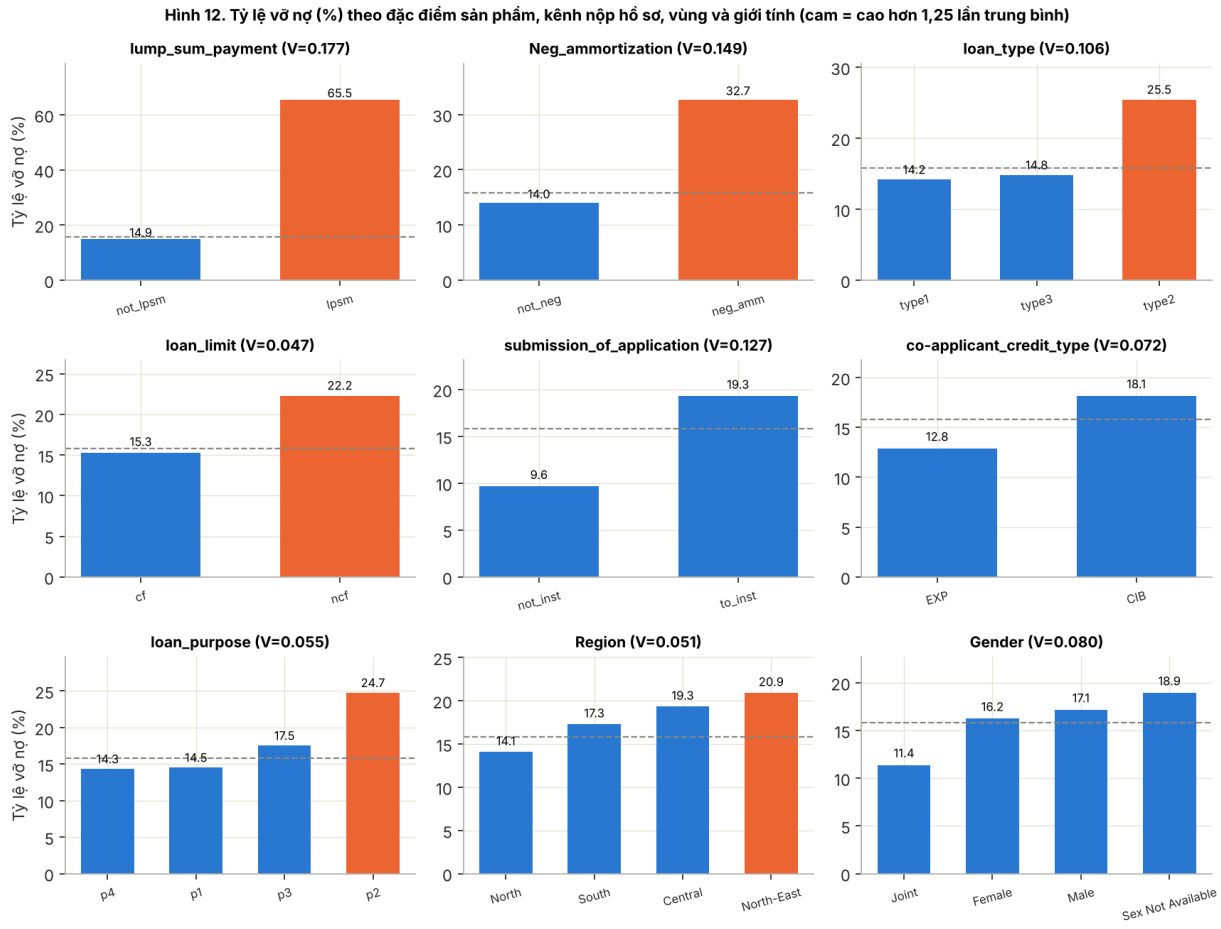
Hình 10. Độ mạnh liên hệ giữa biến phân loại và vỡ nợ (Cramér's V)

Tất cả biến đều có $p < 0,05$ do mẫu rất lớn (133 nghìn dòng), nên cần nhìn độ lớn hiệu ứng (Cramér's V) thay vì chỉ nhìn p-value. Năm biến vượt ngưỡng 0,1: lump_sum_payment (0,177), Neg_ammortization (0,149), submission_of_application (0,127), loan_type và business_or_commercial (cùng 0,106, vì hai cột này trùng thông tin). Các biến nhân khẩu học như Gender (0,080), age (0,052), Region (0,051) chỉ có liên hệ yếu. Đáng chú ý credit_type chỉ còn $V = 0,005$ ($p = 0,19$, không có ý nghĩa thống kê) trong nhóm hồ sơ đầy đủ. Kết luận: đặc điểm cấu trúc sản phẩm vay quan trọng hơn đặc điểm nhân khẩu học của người vay.



Hình 11. Tuổi và loại hồ sơ tín dụng

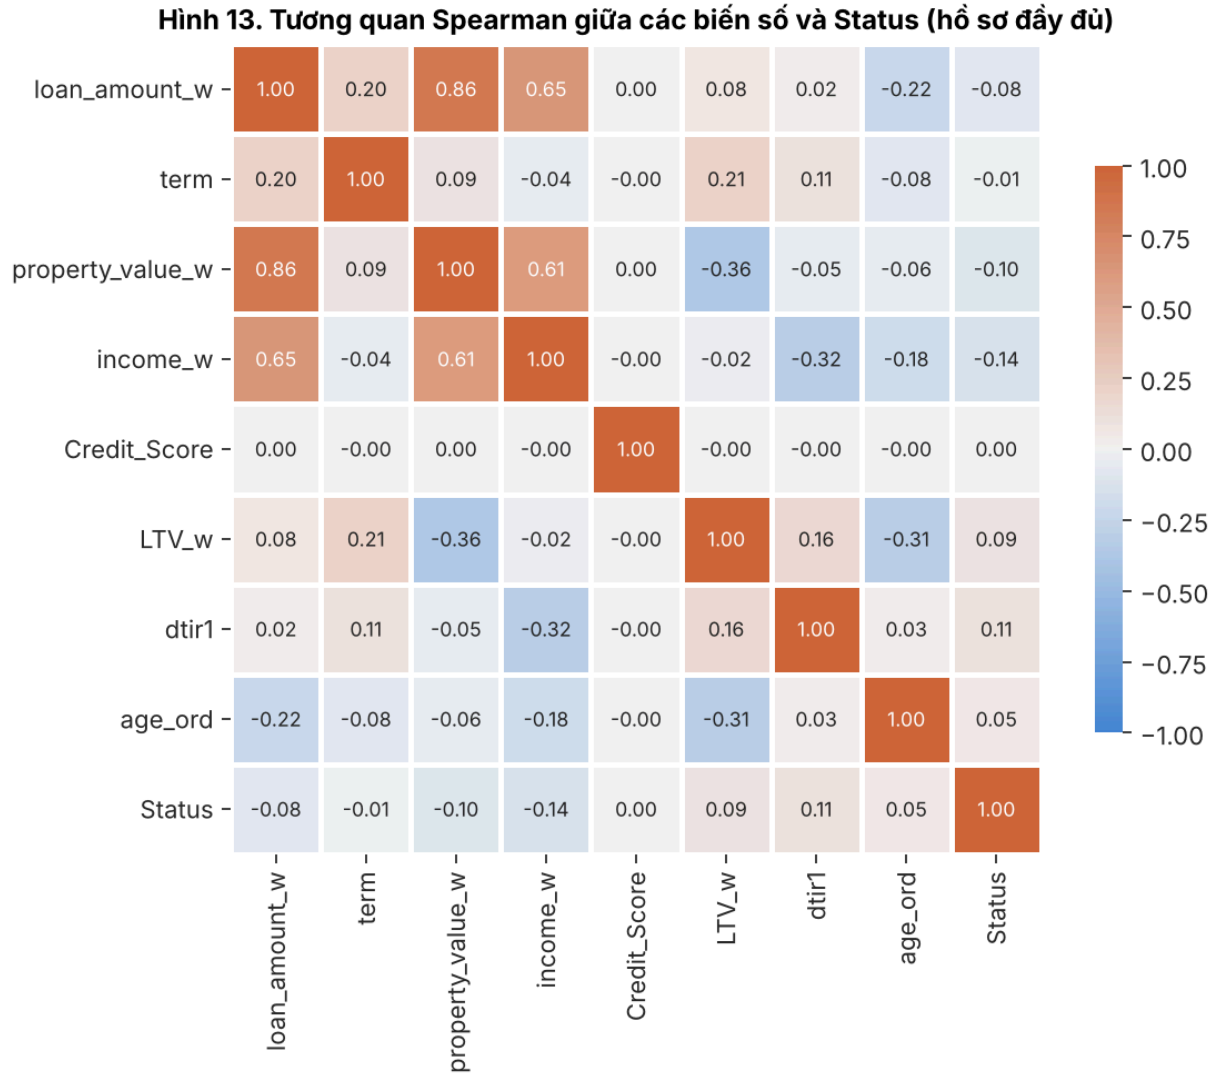
(a) H5 được chấp nhận một phần: tỷ lệ vỡ nợ có dạng chữ U theo tuổi, thấp nhất ở 25–34 (13,34%) và 35–44 (13,62%), cao nhất ở hai đầu là <25 (19,70%) và >74 (19,47%). Giả thuyết "người trẻ rủi ro hơn" chỉ đúng một nửa vì người cao tuổi rủi ro tương đương. Tuy vậy, hiệu ứng yếu (V = 0,052) và nhóm <25 chỉ có 1.183 hồ sơ. (b) Trên toàn bộ dữ liệu, credit_type có V = 0,59 (rất mạnh) vì EQUI có 99,99% vỡ nợ. Sau khi loại hồ sơ không đầy đủ, ba loại còn lại CIB, CRIF, EXP có tỷ lệ gần như bằng nhau (15,59%, 16,02%, 15,77%) và V giảm còn 0,005. Bài học: một liên hệ "rất mạnh" có thể hoàn toàn là sản phẩm của lỗi dữ liệu.



Hình 12. Tỷ lệ vỡ nợ theo đặc điểm sản phẩm, kênh nộp hồ sơ, vùng và giới tính

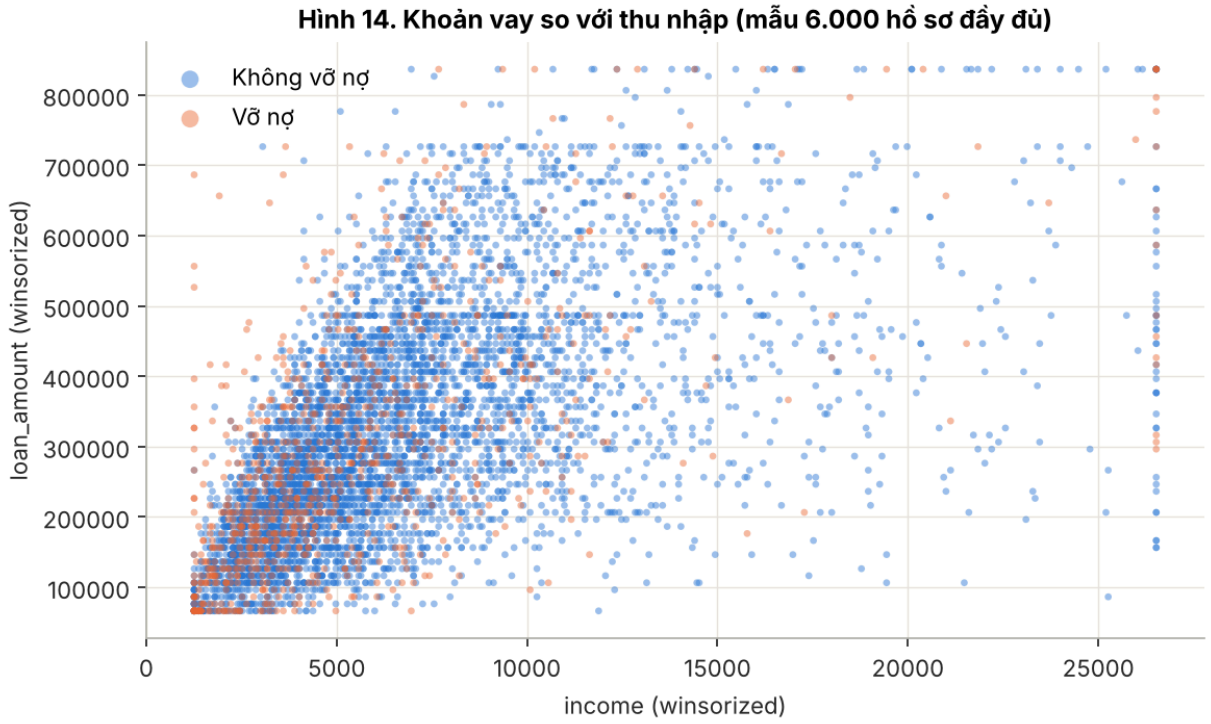
Khoản vay trả gộp cuối kỳ (lpsm) vỡ nợ 65,54% so với 14,95% (gấp 4,4 lần, dù chỉ 2.194 hồ sơ); khoản vay khấu hao âm (neg_amm) 32,71% so với 14,03% (gấp 2,3 lần, 12.455 hồ sơ). Loại vay type2 (trùng với vay kinh doanh/thương mại) có 25,46% so với khoảng 14,2–14,8% của type1/type3. Khoản vay vượt hạn mức chuẩn (ncf) có 22,23% so với 15,31% (cf). Hồ sơ nộp qua kênh to_inst vỡ nợ 19,27%, gấp đôi kênh not_inst (9,64%). Người đồng vay chấm điểm bởi CIB có 18,13% so với 12,85% của EXP. Mục đích vay p2 có 24,73% (n = 2.911) so với 14,30% của p4. Theo vùng, North-East (20,90%, chỉ 1.086 hồ sơ) và Central (19,31%) cao hơn North (14,05%). Theo giới tính, hồ sơ vay chung (Joint) thấp nhất (11,38%), còn hồ sơ không khai giới tính cao nhất (18,93%). Bài học: cấu trúc trả nợ "dồn gánh nặng về sau" (balloon, khấu hao âm) là yếu tố rủi ro lớn nhất; có thêm người cùng vay giúp giảm rủi ro.

3.4. Tương quan và tương tác giữa các biến



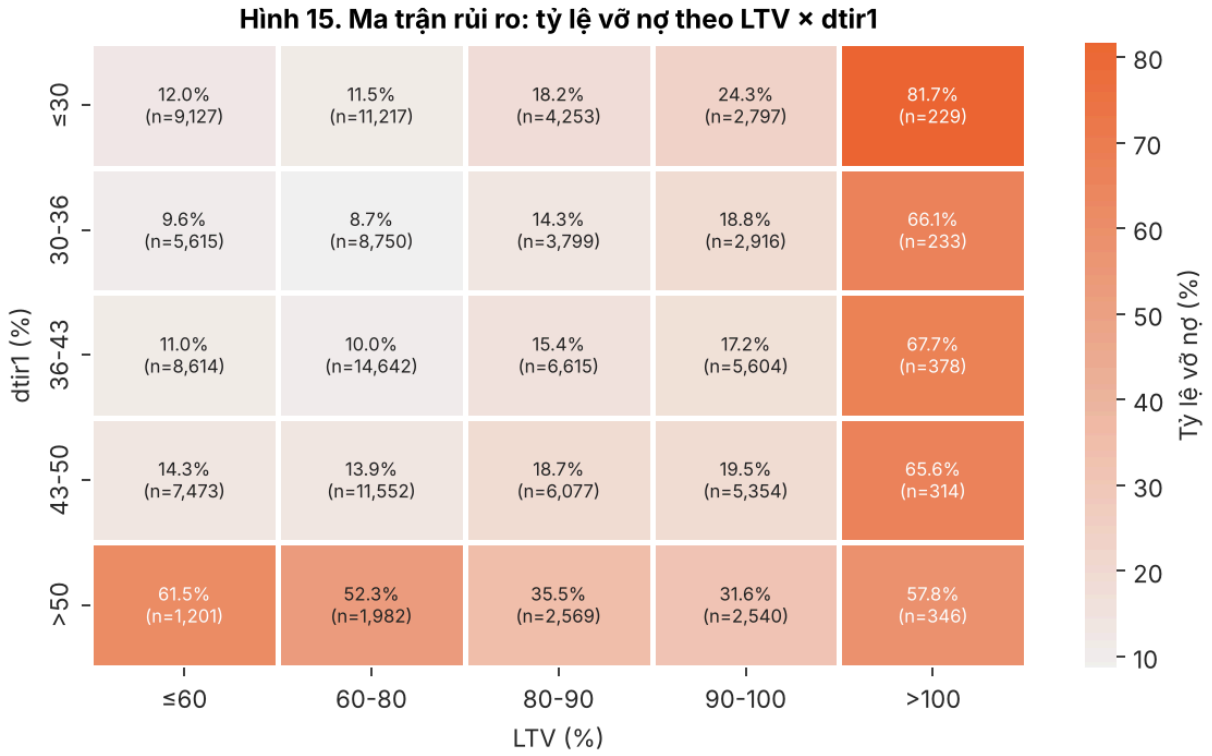
Hình 13. Ma trận tương quan Spearman (hồ sơ đầy đủ)

Không biến số nào có tương quan mạnh với Status: lớn nhất là income (ρ = -0,14), dtir1 (+0,11), property_value (-0,10), LTV (+0,09), loan_amount (-0,08). Credit_Score có ρ = 0,00 với mọi biến, bất thường với một điểm tín dụng thật (điểm phân phối đều 500–900, mỗi khoảng 50 điểm có khoảng 18.500 hồ sơ), gợi ý cột này có thể đã bị ẩn danh hoặc sinh ngẫu nhiên. Giữa các biến đầu vào có đa cộng tuyến: loan_amount–property_value ρ = 0,86, loan_amount–income 0,65, property_value–income 0,61. Vì vậy không nên dùng đồng thời cả ba ở dạng thô trong hồi quy tuyến tính; các tỷ số như LTV hay loan/income mang thông tin rủi ro tốt hơn. Hệ số tương quan nhỏ không có nghĩa là không có tác động: Hình 9 cho thấy quan hệ mang tính ngưỡng mà tương quan đơn điệu đánh giá thấp.



Hình 14. Khoản vay so với thu nhập

Điểm cam (vỡ nợ) tập trung ở góc trái dưới, nơi thu nhập dưới khoảng 5.000. Ở vùng thu nhập trên 10.000 chủ yếu là điểm xanh. Khoản vay và thu nhập tương quan thuận (ρ = 0,65), nhưng rủi ro tăng khi khoản vay vượt quá khả năng thu nhập: chia hồ sơ theo tỷ lệ khoản vay/thu nhập năm (loan / (income × 12)) thành 5 nhóm, bốn nhóm đầu có tỷ lệ vỡ nợ ổn định 14,1–14,6%, còn nhóm cao nhất (khoản vay > 6,2 lần thu nhập năm) tăng lên 23,39%. Bài học: cần một ngưỡng loan-to-income bên cạnh LTV và DTI.



Hình 15. Ma trận rủi ro LTV × dtir1

Kết hợp hai biến cho thấy rủi ro cộng hưởng. Vùng an toàn nhất là dtir1 30–36% với LTV 60–80% (8,7%). Cột LTV > 100% (khoản vay lớn hơn giá trị tài sản) có tỷ lệ vỡ nợ 57,8–81,7% ở mọi mức dtir1 (tổng 1.500 hồ sơ). Hàng dtir1 > 50% cũng đều cao (31,6–61,5%). Điểm bất ngờ: dtir1 > 50% kết hợp LTV ≤ 60% có 61,5%, cao hơn dtir1 > 50% với LTV 90–100% (31,6%). Có thể đây là phân khúc vay đặc thù (ví dụ vay tái cấp vốn rút tiền mặt) cần điều tra thêm. Hàm ý chính sách: chỉ cần vượt một trong hai ngưỡng (LTV > 100% hoặc DTI > 50%) là đủ đẩy rủi ro lên gấp 2–5 lần mức trung bình 15,79%.

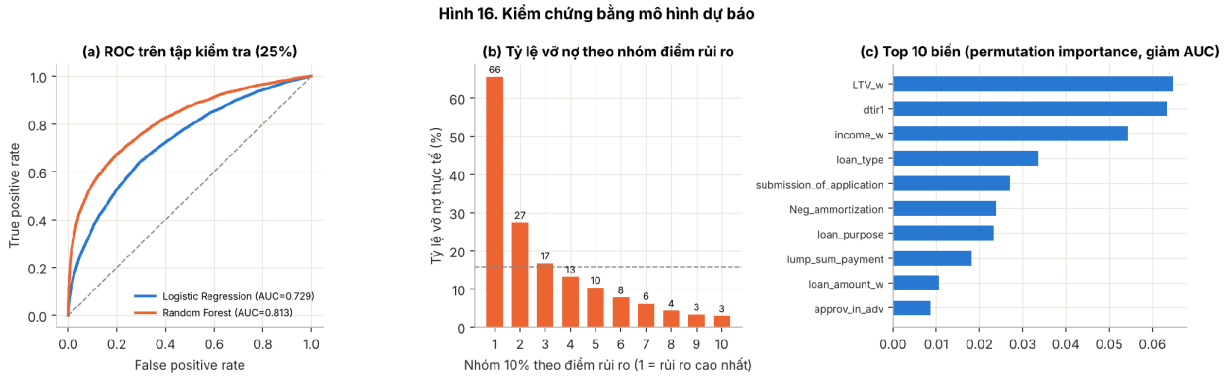
3.5. Kiểm chứng bằng mô hình dự báo

Để kiểm tra các yếu tố trên có thực sự giúp phân biệt hồ sơ tốt và xấu khi xét đồng thời hay không, nhóm huấn luyện hai mô hình trên hồ sơ đầy đủ (75% train, 25% test, phân tầng theo Status) với 8 biến số và 16 biến phân loại, không dùng ba cột rò rỉ và các cột trùng thông tin.

Bảng 5. Kết quả mô hình trên tập kiểm tra (ngưỡng 0,5)

Mô hình	AUC	Recall (vỡ nợ)	Precision (vỡ nợ)	Accuracy
Logistic Regression	0,729	64,1%	28,9%	69,5%

Mô hình	AUC	Recall (vỡ nợ)	Precision (vỡ nợ)	Accuracy
Random Forest	0,813	60,4%	44,7%	82,0%



Hình 16. Kiểm chứng bằng mô hình dự báo

Mô hình được huấn luyện trên hồ sơ đầy đủ, không dùng 3 cột rò rỉ, chia 75/25 có phân tầng. (a) Random Forest đạt AUC = 0,813, cao hơn Logistic Regression (0,729). Khoảng cách này xác nhận quan hệ phi tuyến/ngưỡng đã thấy ở Hình 9 và Hình 15. Ở ngưỡng 0,5, Random Forest bắt được 60,4% ca vỡ nợ (Recall) với Precision 44,7%. (b) Nhóm 10% hồ sơ rủi ro cao nhất có tỷ lệ vỡ nợ thực tế 65,54%, gấp 4,2 lần trung bình; 20% hồ sơ rủi ro nhất chứa 58,9% tổng số ca vỡ nợ, 30% chứa 69,5%. Năm nhóm 10% rủi ro thấp nhất chỉ có 2,9–7,8% vỡ nợ. (c) Theo permutation importance, ba biến quan trọng nhất là LTV (làm giảm AUC 0,065 khi bị xáo trộn), dtir1 (0,063) và income (0,054), tiếp theo là loan_type, submission_of_application, Neg_ammortization, loan_purpose và lump_sum_payment. Credit_Score không nằm trong top 12. Kết quả này trùng khớp với các kiểm định ở trên. Để so sánh: nếu để lọt cột rò rỉ, chỉ một cờ "rate_of_interest bị thiếu" đã cho AUC 0,997, một con số đẹp nhưng vô dụng khi chấm điểm hồ sơ mới.

3.6. Tổng hợp kết quả kiểm định giả thuyết

Bảng 6. Đối chiếu giả thuyết ban đầu với số liệu

	Giả thuyết	Bằng chứng số liệu	Kết luận
H1	Credit_Score càng thấp, vỡ nợ càng cao	Median 699 (không vỡ nợ) và 700 (vỡ nợ); Mann–Whitney p = 0,19; ρ = 0,004; tỷ lệ vỡ nợ theo nhóm điểm 15,1–16,5%	Bác bỏ

	Giả thuyết	Bằng chứng số liệu	Kết luận
H2	LTV càng cao, vỡ nợ càng cao	Median 74,5% và 79,4%; $p < 10^{-200}$; r_rb = 0,14; nhóm LTV 95–103% có 26,8% so với 11,6% ở LTV 65–70%; LTV > 100% có 57,8–81,7%	Chấp nhận (dạng chữ J)
H3	dtir1 càng cao, vỡ nợ càng cao	Median 38% và 42%; $p \approx 0$; r_rb = 0,17; dtir1 ≤ 49% ổn định 12–16%, dtir1 49–61% có 43,1%	Chấp nhận (dạng ngưỡng)
H4	Thu nhập càng cao, vỡ nợ càng thấp	Median 6.000 và 4.680; $p \approx 0$; r_rb = -0,21; giảm từ 30,1% (thập phân vị thấp nhất) xuống khoảng 11%	Chấp nhận
H5	Nhóm tuổi liên hệ với vỡ nợ (người trẻ rủi ro hơn)	χ^2 $p \approx 10^{-74}$, V = 0,052; dạng chữ U: <25 có 19,7%, 25–34 có 13,3%, >74 có 19,5%	Chấp nhận một phần (hiệu ứng yếu)
H6	Đặc điểm sản phẩm, vùng, giới tính liên hệ với vỡ nợ	lump_sum V = 0,177 (65,5% so với 15,0%); neg_amm V = 0,149; submission V = 0,127; loan_type V = 0,106; Region V = 0,051; Gender V = 0,080	Chấp nhận với sản phẩm; yếu với vùng/giới tính

GIAI ĐOẠN 4: ĐÁNH GIÁ TÁC ĐỘNG VÀ KHUYẾN NGHỊ

4.1. Các phát hiện nổi bật

Phát hiện 1. Chất lượng dữ liệu là phát hiện số một: 42,68% số ca vỡ nợ (15.648 hồ sơ) nằm trong nhóm hồ sơ ghi nhận không đầy đủ (thiếu giá trị tài sản, credit_type = EQUI, income = 0, thiếu tuổi), với tỷ lệ vỡ nợ 99,93%. Ba cột lãi suất, chênh lệch lãi suất và phí trả trước thiếu ở 99,45–100% hồ sơ vỡ nợ và gần 0% hồ sơ tốt. Đây là rò rỉ mục tiêu: một cờ thiếu duy nhất cho AUC 0,997.

Phát hiện 2. Năng lực tài chính quyết định rủi ro: DTI > 49% làm tỷ lệ vỡ nợ tăng lên 43,1% (gấp 3,7 lần); LTV > 100% có 57,8–81,7%; nhóm thu nhập thấp nhất có 30,1% so với khoảng 11% ở nhóm thu nhập cao.

Phát hiện 3. Cấu trúc sản phẩm quan trọng hơn nhân khẩu học: khoản vay trả gộp cuối kỳ vỡ nợ 65,5% (gấp 4,4 lần), khấu hao âm 32,7% (gấp 2,3 lần), vay kinh doanh (type2) 25,5%. Trong khi đó, giới tính, vùng, tuổi chỉ có Cramér's V từ 0,05 đến 0,08.

Phát hiện 4. Kênh nộp hồ sơ to_inst có tỷ lệ vỡ nợ 19,3%, gấp đôi kênh not_inst (9,6%). Hồ sơ vay chung (Joint) có rủi ro thấp nhất (11,4%).

Phát hiện 5. Điểm tín dụng (Credit_Score) không có giá trị phân biệt ($p = 0,19$; $\rho = 0,004$) và phân phối đều tuyệt đối trên 500–900, khác hẳn điểm tín dụng thật. Giả thuyết H1 bị bác bỏ.

Phát hiện 6. Một mô hình Random Forest không dùng biến rò rỉ đạt AUC 0,813; 20% hồ sơ rủi ro nhất chứa 58,9% số ca vỡ nợ, còn 50% hồ sơ rủi ro thấp nhất chỉ có 2,9–7,8% vỡ nợ.

4.2. Đề xuất giải pháp

Các giải pháp được sắp xếp theo thứ tự ưu tiên. Giải pháp số 1 là điều kiện tiên quyết: mọi mô hình chấm điểm chỉ đáng tin khi dữ liệu đầu vào phản ánh đúng thông tin có tại thời điểm xét duyệt.

Bảng 7. Đề xuất giải pháp ứng dụng

STT	Giải pháp	Nội dung thực hiện	Căn cứ số liệu
1	Sửa quy trình dữ liệu	Kiểm toán lý do rate_of_interest, Upfront_charges, property_value bị bỏ trống ở hồ sơ vỡ nợ và lý do mọi hồ sơ	Loại bỏ rò rỉ; mô hình chấm điểm phản ánh đúng

STT	Giải pháp	Nội dung thực hiện	Căn cứ số liệu
		EQUI đều vỡ nợ. Lưu ảnh chụp dữ liệu tại thời điểm xét duyệt (snapshot) thay vì dữ liệu cập nhật sau giải ngân. Ban hành từ điển dữ liệu chuẩn.	thông tin có lúc ra quyết định
2	Trần LTV	Đặt trần LTV khoảng 90–95%; với LTV > 100% bắt buộc bảo đảm bổ sung hoặc bảo hiểm khoản vay.	Nhóm LTV > 100% vỡ nợ 57,8–81,7%; nhóm 95–103% có 26,8%
3	Trần DTI	Đặt trần dtir1 khoảng 45–49%. Trên mức này yêu cầu người đồng vay, giảm số tiền vay hoặc kéo dài kỳ hạn.	Rủi ro tăng từ 16% lên 43% khi dtir1 vượt khoảng 49%
4	Ngưỡng khoản vay/thu nhập	Thẩm định khả năng trả nợ kỹ hơn khi khoản vay vượt 6 lần thu nhập năm hoặc thu nhập thuộc nhóm 10% thấp nhất.	Nhóm khoản vay/thu nhập cao nhất có 23,4%; thu nhập thấp nhất có 30,1%
5	Kiểm soát sản phẩm rủi ro	Hạn chế hoặc định giá rủi ro cao hơn cho khoản vay trả gộp cuối kỳ và khấu hao âm; phê duyệt cấp cao hơn cho vay kinh doanh (type2) và mục đích p2.	lpsm 65,5%, neg_amm 32,7%, type2 25,5%, p2 24,7%
6	Rà soát kênh to_inst	Rà soát chất lượng thẩm định của kênh nộp to_inst (đối tác, môi giới) và đặt chỉ tiêu chất lượng hồ sơ theo kênh.	Tỷ lệ vỡ nợ gấp đôi kênh not_inst (19,3% so với 9,6%)
7	Phân luồng hồ sơ bằng mô hình	Chấm điểm bằng mô hình: 20% rủi ro nhất chuyển thẩm định thủ công, 50% rủi ro thấp nhất xét duyệt nhanh. Ngưỡng cắt cần tính theo tổn thất kỳ vọng (PD × LGD × EAD).	Top 20% chứa 58,9% ca vỡ nợ; 50% thấp nhất chỉ 2,9–7,8%
8	Đảm bảo công bằng	Không dùng Gender, age làm biến ra quyết định; dùng chúng để kiểm tra mô hình có phân biệt đối xử hay không.	Hiệu ứng nhỏ ($V \leq 0,08$) nhưng rủi ro pháp lý và uy tín lớn

Ước tính tác động: trên tập kiểm tra, nếu chuyển 20% hồ sơ có điểm rủi ro cao nhất sang thẩm định thủ công, ngân hàng sẽ rà soát được 58,9% số ca vỡ nợ trong khi chỉ tăng khối lượng thẩm định cho 1/5 số hồ sơ. Đồng thời, 50% hồ sơ rủi ro thấp nhất (tỷ lệ vỡ nợ 2,9–7,8%, so với trung bình 15,79%) có thể được xét duyệt nhanh, rút ngắn thời gian phục vụ khách hàng tốt.

4.3. Giới hạn của tập dữ liệu

Không có từ điển dữ liệu chính thức: ý nghĩa của các mã p1–p4, type1–3, l1/l2, cf/ncf, to_inst và đơn vị của income (giả định theo tháng) chỉ được suy luận từ tên cột.

Dữ liệu chỉ có năm 2019 (một lát cắt): không kiểm định được tác động kinh tế vĩ mô, mùa vụ, và không kiểm tra được mô hình ngoài thời gian (out-of-time). Định nghĩa vỡ nợ (bao nhiêu ngày quá hạn, trong khoảng thời gian nào) không được công bố.

Rò rỉ và thiếu không ngẫu nhiên (MNAR): việc tách nhóm hồ sơ không đầy đủ giúp phân tích trung thực hơn, nhưng làm mất 42,68% ca vỡ nợ. Kết luận ở Giai đoạn 3 chỉ đại diện cho hồ sơ được ghi nhận đầy đủ (có thể có thiên lệch chọn mẫu).

Credit_Score có dấu hiệu bị ẩn danh hoặc sinh ngẫu nhiên (phân phối đều, tương quan 0 với mọi biến), nên không đánh giá được vai trò thật của điểm tín dụng.

Dữ liệu quan sát cắt ngang chỉ cho thấy liên hệ, chưa chứng minh quan hệ nhân quả (ví dụ kênh to_inst có thể tập trung khách hàng rủi ro chứ bản thân kênh không gây ra vỡ nợ).

4.4. Hướng mở rộng trong tương lai

Thu thập dữ liệu nhiều năm kèm ngày giải ngân và ngày vỡ nợ để kiểm định ngoài thời gian và áp dụng phân tích sống sót (thời gian đến khi vỡ nợ).

Bổ sung lịch sử tín dụng thật, thông tin việc làm, biến vĩ mô (lãi suất, giá nhà, thất nghiệp theo vùng).

Thử mô hình Gradient Boosting (XGBoost/LightGBM) kèm giải thích SHAP, hiệu chỉnh xác suất (calibration) và chọn ngưỡng theo chi phí.

Xây dựng thẻ điểm (scorecard) WoE/IV để dễ giải trình với cơ quan quản lý; kiểm toán công bằng theo giới tính và độ tuổi.

Làm việc với bộ phận vận hành để xác minh nguyên nhân của các trường bị bỏ trống, rồi chạy lại toàn bộ phân tích trên dữ liệu đã sửa.

PHỤ LỤC: TÁI LẬP KẾT QUẢ

Toàn bộ kết quả trong báo cáo được tạo bởi notebook Loan_Default_Analysis.ipynb đi kèm. Cách chạy lại như sau:

1. Tải Loan_Default.csv từ Kaggle và đặt cùng thư mục với notebook.
2. Cài thư viện: pip install pandas numpy matplotlib seaborn scipy scikit-learn.
3. Mở notebook bằng Jupyter và chọn Run All. Các biểu đồ được lưu vào thư mục figures/, còn các con số chính được lưu trong results.json.

Môi trường đã dùng: Python 3.13, pandas 3.0, scikit-learn 1.9, matplotlib 3.11, seaborn 0.13, scipy 1.18. Các bước ngẫu nhiên (chia train/test, Random Forest, lấy mẫu biểu đồ) đều cố định random_state = 42 nên kết quả lặp lại được.